

*Ministère de l'Enseignement Supérieur et de la
Recherche Scientifique*

Année Académique : 2025-2026



*Université Polytechnique de
Bingerville*

MASTER 1

DATA-IA

MODULE: PROGRAMMATION R

RAPPORT DU PROJET DE FIN DE MODULE DE PROGRAMMATION R

Segmentation de la clientèle e-commerce par analyse RFM et clustering K-means

Réalisé par :

YAO MIÉZAN SAM WILLIAM

Enseignant :

Dr. TALNAN

Table des matières

Table des matières	i
Liste des figures.....	ii
Liste des tableaux	iii
1. Introduction	1
1.1 Présentation du jeu de données.....	1
1.2 Objectifs du projet	2
2. Méthodologie.....	3
2.1 Nettoyage des données	3
2.2 Construction des indicateurs RFM	3
2.3 Détection des valeurs aberrantes (méthode IQR)	4
2.4 Transformation et standardisation	4
2.5 Détermination du nombre optimal de clusters.....	5
3. Résultats	7
3.1 Segmentation K-means ($k = 4$)	7
3.2 Profils des segments	7
3.3 Validation par clustering hiérarchique	9
4. Interprétation métier et recommandations.....	10
4.1 Champions (723 clients, 16,7 %)	10
4.2 Fidèles réguliers (1 158 clients, 26,7 %)	10
4.3 Récents / occasionnels (878 clients, 20,2 %)	10
4.4 Inactifs / perdus (1 579 clients, 36,4 %)	10
5. Conclusion.....	11
5.1 Bilan du projet	11
5.2 Limites du projet.....	11
5.3 Perspectives	11
Bibliographie	12
Annexe : Code R complet	13
Environnement technique	13

Liste des figures

Figure 1 : Boxplots des variables RFM brutes (avant transformation), détection des outliers ...	4
Figure 2 : Distribution du Montant avant et après transformation logarithmique	5
Figure 3 : Méthode du coude (Within Sum of Squares)	6
Figure 4 : Score de silhouette moyen selon le nombre de clusters	6
Figure 5 : Projection des 4 segments sur les deux premières composantes principales	7
Figure 6 : Distribution des variables RFM par segment	8
Figure 7 : Nombre de clients par segment	8
Figure 8 : Dendrogramme du clustering hiérarchique (échantillon de 500 clients)	9

Liste des tableaux

Tableau 1 : Variables du jeu de données Online Retail	1
Tableau 2 : Nombre d'outliers détectés par variable RFM (méthode IQR)	4
Tableau 3 : Profils moyens des 4 segments de clients	7
Tableau 4 : Bilan récapitulatif des étapes du projet	11

1. Introduction

Quand une entreprise vend en ligne, elle accumule vite des milliers de transactions, mais tous ses clients ne se ressemblent pas : certains reviennent souvent et dépensent beaucoup, d'autres n'ont acheté qu'une fois et ont disparu depuis. Pour une stratégie marketing efficace, il est essentiel de distinguer ces profils plutôt que de traiter tout le monde de la même façon. C'est l'objectif de ce projet : utiliser la méthode RFM (Récence, Fréquence, Montant) associée à un algorithme de clustering (K-means) pour regrouper automatiquement les clients d'un site de vente en ligne selon leur comportement d'achat réel.

Ce travail poursuit deux objectifs. Le premier est de mettre en pratique les compétences acquises en programmation R : manipulation, nettoyage et transformation de données, puis modélisation. Le second, tout aussi important, est de produire un résultat réellement exploitable: identifier des groupes de clients cohérents et en tirer des recommandations concrètes, comme le ferait une équipe marketing en entreprise.

1.1 Présentation du jeu de données

Le jeu de données utilisé est « Online Retail », mis à disposition par le UCI Machine Learning Repository^[1]. Il regroupe l'ensemble des transactions réalisées entre le 1er décembre 2010 et le 9 décembre 2011 par un site de vente en ligne britannique spécialisé dans les articles cadeaux. Chaque ligne correspond à un produit acheté dans le cadre d'une commande, avec les colonnes suivantes :

Variable	Description
InvoiceNo	Numéro de facture (identifiant de commande)
StockCode	Code produit
Description	Libellé du produit
Quantity	Quantité commandée
InvoiceDate	Date et heure de la commande
UnitPrice	Prix unitaire (en livres sterling)
CustomerID	Identifiant unique du client
Country	Pays du client

Tableau 1 : Variables du jeu de données Online Retail

Tel quel, ce fichier brut compte 541 909 lignes pour 4 373 clients uniques, répartis sur 38 pays. Le Royaume-Uni domine très largement (91,4 % des lignes), ce qui est cohérent avec la nature du site.

1.2 Objectifs du projet

Concrètement, la démarche se déroule en plusieurs étapes :

- nettoyer les données pour ne garder que des transactions valides,
- calculer, pour chaque client, ses indicateurs Récence / Fréquence / Montant,
- transformer et standardiser ces indicateurs pour qu'ils soient exploitables par un algorithme de clustering,
- choisir un nombre de groupes pertinent à l'aide de la méthode du coude et du score de silhouette,
- appliquer K-means, puis vérifier la cohérence du résultat avec un clustering hiérarchique,
- enfin, donner du sens à chaque groupe et proposer des actions marketing adaptées.

2. Méthodologie

2.1 Nettoyage des données

Un premier coup d'œil sur les données brutes fait apparaître plusieurs problèmes : 135 080 lignes n'ont pas d'identifiant client renseigné, 10 624 lignes ont une quantité négative (ce sont en réalité des retours ou des annulations de commande), et 2 517 lignes affichent un prix unitaire nul ou négatif, probablement des erreurs de saisie. Aucune de ces lignes ne correspond à un achat réel, donc elles ont toutes été écartées avant de poursuivre, car les garder aurait faussé le calcul des indicateurs RFM.

```
data_clean <- data %>%
  filter(!is.na(CustomerID)) %>%
  filter(Quantity > 0) %>%
  filter(UnitPrice > 0) %>%
  mutate(
    InvoiceDate = as_datetime(InvoiceDate),
    TotalPrice = Quantity * UnitPrice
  )
```

Une fois ce nettoyage effectué, il reste 397 884 lignes, soit 73,4 % du volume de départ, et 4 338 clients sur les 4 373 initiaux. Autrement dit, on ne perd quasiment aucun client (99,2 % conservés), ce qui est plutôt rassurant sur la qualité du nettoyage.

2.2 Construction des indicateurs RFM

L'étape suivante consiste à résumer, pour chaque client, l'ensemble de son historique d'achat en trois chiffres seulement, selon l'approche RFM classique en analyse client^[8]. La date de référence retenue est le 10 décembre 2011, soit le lendemain de la dernière transaction du jeu de données :

- Récence (R) : le nombre de jours écoulés depuis le dernier achat du client
- Fréquence (F) : le nombre de commandes distinctes qu'il a passées
- Montant (M) : la somme totale qu'il a dépensée sur la période

```
rfm <- data_clean %>%
  group_by(CustomerID) %>%
  summarise(
    Recency = as.numeric(difftime(date_ref, max(InvoiceDate), units = "days")),
    Frequency = n_distinct(InvoiceNo),
    Monetary = sum(TotalPrice)
  ) %>% ungroup()
```

En regardant la distribution de ces trois variables, on remarque tout de suite un problème : le Montant est très déséquilibré. Un client a par exemple dépensé 77 184 £ en un seul achat, alors que la moitié des clients dépensent moins de 674 £ sur toute la période. Si on ne corrige pas ça, ce genre de valeur extrême va complètement dominer les calculs de distance utilisés par K-means, et la segmentation n'aura plus aucun sens.

2.3 Détection des valeurs aberrantes (méthode IQR)

Avant de corriger quoi que ce soit, il est utile d'objectiver le problème avec la méthode IQR (Interquartile Range) : est considérée comme aberrante toute valeur en dehors de l'intervalle $[Q1 - 1,5 \times IQR ; Q3 + 1,5 \times IQR]$.




Figure 1 : Boxplots des variables RFM brutes (avant transformation)

Variable	Nombre d'outliers	Part des clients
Récence	155	3,6 %
Fréquence	285	6,6 %
Montant	427	9,8 %

Tableau 2 : Nombre d'outliers détectés par variable RFM (méthode IQR)

Le Montant est la variable la plus touchée, avec près d'un client sur dix considéré comme aberrant au sens strict de l'IQR. Comme ces clients ne sont pas des erreurs de mesure mais bien des achats réels (gros acheteurs occasionnels, probablement des professionnels ou revendeurs), il n'est pas question de les supprimer : ce sont potentiellement des profils intéressants à conserver dans l'analyse. C'est ce constat qui justifie le choix, présenté ci-dessous, d'une transformation logarithmique plutôt que d'une suppression ou d'une winsorisation stricte.

2.4 Transformation et standardisation

Pour limiter l'effet de ces valeurs extrêmes sans pour autant les supprimer (elles restent des clients réels), une transformation logarithmique $\log(1+x)$ a été appliquée aux trois variables. L'ordre entre les clients est conservé, mais les écarts extrêmes sont resserrés. On le voit bien sur la variable Montant :




Figure 2 : *Distribution du Montant avant et après transformation logarithmique*

La distribution passe d'une forme complètement écrasée à gauche à quelque chose qui ressemble davantage à une courbe en cloche, beaucoup plus adaptée au clustering. Une fois ces variables transformées, elles ont été standardisées (centrées-réduites) pour que Récence, Fréquence et Montant pèsent chacune du même poids dans le calcul des distances.

2.5 Détermination du nombre optimal de clusters

Avant de lancer K-means, il faut décider combien de groupes on cherche à former. Deux méthodes classiques, disponibles dans le package `factoextra`^[4], ont été combinées pour trancher cette question : la méthode du coude et le score de silhouette^[7].




Figure 3 : Méthode du coude (Within Sum of Squares)




Figure 4 : Score de silhouette moyen selon le nombre de clusters

Le score de silhouette est techniquement le plus élevé pour $k = 2$, mais ce découpage revient juste à séparer les « gros » clients des « petits », ce qui est trop pauvre pour construire une vraie stratégie marketing. En regardant la suite de la courbe, on voit qu'elle reste stable entre $k = 3$ et $k = 8$ (le score varie peu, entre 0,30 et 0,34), donc plusieurs choix restent statistiquement défendables. La méthode du coude, de son côté, montre une cassure assez nette entre $k = 2$ et $k = 4$. Au final, $k = 4$ a été retenu : c'est un compromis courant en segmentation RFM (on vise généralement 4 à 5 groupes) qui reste bien soutenu par les deux graphiques, tout en donnant assez de granularité pour distinguer des profils marketing utiles.

3. Résultats

3.1 Segmentation K-means (k = 4)

Le clustering final a été réalisé avec l'algorithme K-means^[6], tel qu'implémenté dans R :

```
set.seed(123)
km_result <- kmeans(rfm_scaled, centers = 4, nstart = 25)
```




Figure 5 : Projection des 4 segments sur les deux premières composantes principales

En projetant les résultats sur deux dimensions grâce à une analyse en composantes principales (qui explique 93,8 % de la variance, donc on ne perd presque rien en simplifiant), on voit quatre groupes de clients plutôt bien séparés. Il y a un léger chevauchement entre les segments 1 et 4, ce qui est logique : la frontière entre un client « fidèle » et un client « très actif » est forcément progressive, pas nette.

3.2 Profils des segments

Segment	Clients	Récence moy.	Fréquence moy.	Montant moy.
Champions	723	12,5 jours	13,6 commandes	8 013 £
Fidèles réguliers	1 158	69,3 jours	4,13 commandes	1 810 £
Récents / occasionnels	878	20,5 jours	2,05 commandes	530 £
Inactifs / perdus	1 579	188,0 jours	1,33 commande	352 £

Tableau 3 : Profils moyens des 4 segments de clients




Figure 6 : Distribution des variables RFM par segment




Figure 7 : Nombre de clients par segment

3.3 Validation par clustering hiérarchique

Pour ne pas se fier uniquement à K-means, un second algorithme a été testé en complément : un clustering hiérarchique selon la méthode de Ward^[9] (distance euclidienne), appliqué cette fois sur un échantillon de 500 clients pour rester raisonnable en temps de calcul.




Figure 8 : Dendrogramme du clustering hiérarchique (échantillon de 500 clients)

Le dendrogramme obtenu montre quatre branches bien distinctes, qui se séparent à une hauteur cohérente. Ce résultat va dans le même sens que celui de K-means : les deux méthodes, pourtant très différentes dans leur fonctionnement, arrivent à une structure en quatre groupes. C'est un bon indice que la segmentation reflète une réalité dans les données, et pas un artefact lié au choix d'un algorithme en particulier.

4. Interprétation métier et recommandations

Avoir quatre groupes de chiffres, c'est bien, mais ça ne sert à rien tant qu'on ne leur donne pas un sens business. Voici comment chaque segment peut se lire, et ce qu'on ferait concrètement avec, si on était l'équipe marketing du site.

4.1 Champions (723 clients, 16,7 %)

Ce sont les meilleurs clients du site, sans ambiguïté : ils ont acheté il y a 12,5 jours en moyenne, ont passé 13,6 commandes, et dépensé 8 013 £ en moyenne sur la période. Ils sont peu nombreux, mais ce sont eux qui font tourner la boutique.

- Leur proposer un programme de fidélité premium, avec de vrais avantages exclusifs
- Leur donner un accès prioritaire aux nouveautés et aux ventes privées
- Aller chercher leur avis : ce sont probablement les meilleurs ambassadeurs de la marque

4.2 Fidèles réguliers (1 158 clients, 26,7 %)

Un cran en dessous des Champions, mais toujours un bon niveau d'engagement : environ 69 jours depuis le dernier achat, 4 commandes en moyenne, 1 810 £ dépensés. C'est un segment intéressant parce qu'avec le bon coup de pouce, une partie de ces clients pourrait basculer vers le groupe des Champions.

- Cibler ce groupe avec des offres de cross-selling / up-selling
- Proposer des avantages fidélité pour les inciter à acheter plus souvent
- Garder un contact régulier pour ne pas les laisser s'éloigner

4.3 Récents / occasionnels (878 clients, 20,2 %)

Ces clients ont acheté récemment (20,5 jours en moyenne) mais seulement 2 commandes en moyenne, pour 530 £. Tout laisse penser qu'il s'agit surtout de nouveaux clients encore en phase de découverte du site.

- Mettre en place une séquence de bienvenue qui présente le catalogue
- Proposer une offre de réachat pour transformer l'essai en habitude
- Suivre leur évolution pour voir s'ils basculent vers le segment des fidèles

4.4 Inactifs / perdus (1 579 clients, 36,4 %)

C'est le groupe le plus fourni, et le plus préoccupant : en moyenne 188 jours sans achat, à peine 1,33 commande sur toute la période, et 352 £ dépensés. Ces clients se sont clairement éloignés du site et risquent d'être définitivement perdus s'il n'y a pas d'action.

- Lancer des campagnes de réactivation avec une offre suffisamment incitative
- Chercher à comprendre pourquoi ils sont partis (enquête de satisfaction)
- Ne pas viser tout le monde en priorité : mieux vaut concentrer le budget sur les clients ayant le plus de chances de revenir

5. Conclusion

5.1 Bilan du projet

Le tableau ci-dessous résume, étape par étape, le déroulement du projet et ce qu'il en ressort :

Étape	Résultat
Nettoyage	397 884 lignes conservées (73,4 %) ; 4 338 clients sur 4 373 (99,2 %)
Indicateurs RFM	Récence, Fréquence, Montant calculés pour chaque client
Détection des outliers	Jusqu'à 9,8 % de valeurs extrêmes sur le Montant (méthode IQR)
Transformation	Log(1+x) puis standardisation des 3 variables
Choix du nombre de clusters	k = 4 (méthode du coude + score de silhouette)
Clustering	K-means (k = 4), validé par un clustering hiérarchique (Ward)
Segments obtenus	Champions, Fidèles réguliers, Récents/occasionnels, Inactifs/perdus

Tableau 4 : Bilan récapitulatif des étapes du projet

Ce projet a permis de suivre, de bout en bout, une véritable chaîne de traitement de données en R : partir d'un fichier de transactions brutes, le nettoyer, en extraire des indicateurs pertinents, gérer les problèmes de distribution, choisir un modèle de clustering de façon justifiée, puis interpréter les résultats en termes concrets. La méthode RFM, couplée à K-means et vérifiée par un clustering hiérarchique, a permis de faire ressortir quatre profils de clients nets et cohérents, chacun appelant une réponse marketing différente.

5.2 Limites du projet

Cette segmentation reste perfectible sur plusieurs points, qu'il est honnête de mentionner :

- Elle repose uniquement sur des indicateurs transactionnels (R, F, M) et ignore le type de produits achetés, qui pourrait affiner encore les profils
- Elle ne tient pas compte de la saisonnalité : un client actif seulement à Noël peut être classé comme peu fréquent alors qu'il est fidèle sur son propre rythme d'achat
- La transformation logarithmique, bien qu'utile, réduit l'écart entre gros et petits acheteurs : un client à 8 000 £ et un client à 20 000 £ peuvent finir dans le même segment
- La segmentation est figée dans le temps : elle photographie le comportement des clients entre décembre 2010 et décembre 2011, et devrait être recalculée régulièrement pour rester pertinente
- Le choix de k = 4 reste une décision de compromis ; un autre analyste aurait pu raisonnablement choisir k = 3 ou k = 5

5.3 Perspectives

Pour aller plus loin, il serait intéressant d'ajouter d'autres variables (type de produits achetés, saisonnalité, canal d'acquisition) ou de refaire cette segmentation régulièrement, pour suivre comment les clients évoluent d'un groupe à l'autre dans le temps.

Bibliographie

- [1] UCI Machine Learning Repository. Online Retail Data Set. Consulté sur <https://archive.ics.uci.edu/dataset/352/online+retail>
- [2] Wickham, H., Çetinkaya-Rundel, M., & Grolemund, G. (2023). R for Data Science (2^e éd.). O'Reilly Media. Disponible sur <https://r4ds.hadley.nz/>
- [3] Kassambara, A. (2017). Practical Guide to Cluster Analysis in R: Unsupervised Machine Learning. STHDA.
- [4] Kassambara, A. Documentation du package factoextra : Extract and Visualize the Results of Multivariate Data Analyses. <https://rpkgs.datanovia.com/factoextra/>
- [5] Wickham, H. et al. Documentation du package dplyr : A Grammar of Data Manipulation. <https://dplyr.tidyverse.org/>
- [6] Hartigan, J. A., & Wong, M. A. (1979). Algorithm AS 136: A K-Means Clustering Algorithm. Journal of the Royal Statistical Society, Series C, 28(1), 100–108.
- [7] Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53–65.
- [8] Fader, P. S., Hardie, B. G. S., & Lee, K. L. (2005). RFM and CLV: Using Iso-Value Curves for Customer Base Analysis. Journal of Marketing Research, 42(4), 415–430.
- [9] Ward, J. H. (1963). Hierarchical Grouping to Optimize an Objective Function. Journal of the American Statistical Association, 58(301), 236–244.

Annexe : Code R complet

Environnement technique

- Langage : R (version 4.5.2)

Packages utilisés : readxl, dplyr^[5], lubridate, ggplot2, gridExtra, factoextra^[4], tidyr (voir aussi R for Data Science^[2] pour la logique générale de manipulation de données adoptée dans ce script)

- Source des données : UCI Machine Learning Repository, Online Retail Data Set

Le script ci-dessous reprend l'intégralité du code utilisé pour ce projet, de l'import des données jusqu'à l'export des résultats finaux.

IMPORTATION DES LIBRAIRIES

```
library(readxl)  # Import du fichier Excel
library(dplyr)   # Manipulation de données
library(lubridate) # Gestion des dates
library(ggplot2)  # Visualisation
library(gridExtra) # Assemblage de graphiques
library(factoextra) # Clustering (nombre optimal de clusters, visualisation)
library(tidyr)    # Remise en forme des données (pivot_longer)
```

1. IMPORT DES DONNÉES

```
data <- read_excel("Online Retail.xlsx")
```

2. EXPLORATION DU DATASET

```
str(data)
summary(data)
glimpse(data)

## Valeurs manquantes par colonne
colSums(is.na(data))

## Quantités négatives
sum(data$Quantity < 0)

## Prix unitaires nuls ou négatifs
sum(data$UnitPrice <= 0)

## Nombre de clients uniques
n_distinct(data$CustomerID)

## Répartition des transactions par pays
table(data$Country)
```

3. NETTOYAGE DES DONNÉES

```
## Objectif : ne garder que les transactions valides (achats réels, client connu)
```

```
data_clean <- data %>%
  filter(!is.na(CustomerID)) %>% # retirer les commandes sans client identifié
  filter(Quantity > 0) %>%      # retirer les retours (quantités négatives)
  filter(UnitPrice > 0) %>%     # retirer les prix aberrants
  mutate(
    InvoiceDate = as_datetime(InvoiceDate),
    TotalPrice = Quantity * UnitPrice # montant de la ligne de commande
  )
```

```
## Vérification post-nettoyage
```

```
str(data_clean)
nrow(data_clean)
n_distinct(data_clean$CustomerID)
```

4. CALCUL DES INDICATEURS RFM

```
## R = Récence : nombre de jours depuis le dernier achat
```

```
## F = Fréquence : nombre de commandes distinctes
```

```
## M = Montant : somme totale dépensée
```

```
# Date de référence : dernier jour du dataset + 1 jour
```

```
date_ref <- max(data_clean$InvoiceDate) + days(1)
```

```
rfm <- data_clean %>%
  group_by(CustomerID) %>%
  summarise(
    Recency = as.numeric(difftime(date_ref, max(InvoiceDate), units = "days")),
    Frequency = n_distinct(InvoiceNo),
    Monetary = sum(TotalPrice)
  ) %>%
  ungroup()
```

```
## Vérification
```

```
str(rfm)
summary(rfm)
head(rfm, 10)
```

5. DÉTECTION DES VALEURS ABERRANTES (MÉTHODE IQR)

On visualise puis on quantifie les outliers sur les variables RFM brutes,
 ## avant toute transformation, pour objectiver le choix méthodologique
 ## qui suit (transformation logarithmique plutôt que suppression).

Boxplots des variables RFM brutes

```
rfm %>%
  select(Recency, Frequency, Monetary) %>%
  pivot_longer(everything(), names_to = "Variable", values_to = "Valeur") %>%
  ggplot(aes(x = Variable, y = Valeur)) +
  geom_boxplot(fill = "#4C72B0", alpha = 0.7) +
  facet_wrap(~Variable, scales = "free") +
  theme_minimal() +
  ggtitle("Détection des valeurs aberrantes (méthode IQR), variables RFM brutes")
```

Quantification des outliers par variable (bornes IQR classiques)

```
for (col in c("Recency", "Frequency", "Monetary")) {
  Q1 <- quantile(rfm[[col]], 0.25)
  Q3 <- quantile(rfm[[col]], 0.75)
  IQR_val <- Q3 - Q1
  borne_inf <- Q1 - 1.5 * IQR_val
  borne_sup <- Q3 + 1.5 * IQR_val
  n_out <- sum(rfm[[col]] < borne_inf | rfm[[col]] > borne_sup)
  cat(sprintf("%-12s : %d outliers (%.1f%%)\n", col, n_out, 100 * n_out / nrow(rfm)))
}
```

6. TRANSFORMATION LOGARITHMIQUE

Les variables RFM sont fortement asymétriques.
 ## On applique log(1+x) pour réduire l'effet des valeurs extrêmes
 ## plutôt que de supprimer les clients concernés (ce sont des achats réels).

```
rfm_log <- rfm %>%
  mutate(
    Recency_log = log1p(Recency),
    Frequency_log = log1p(Frequency),
    Monetary_log = log1p(Monetary)
  )
```

```
head(rfm_log, 10)
```

Comparaison visuelle avant / après transformation de la variable Monetary

```
p1 <- ggplot(rfm, aes(x = Monetary)) +
  geom_histogram(bins = 50) +
  ggtitle("Monetary (brut)")
```

```

p2 <- ggplot(rfm_log, aes(x = Monetary_log)) +
  geom_histogram(bins = 50) +
  ggtitle("Monetary (log)")

grid.arrange(p1, p2, ncol = 2)

# 7. STANDARDISATION

## Centrage-réduction des variables log-transformées, pour que chaque
## dimension pèse équitablement dans le calcul des distances (K-means).

rfm_scaled <- rfm_log %>%
  select(Recency_log, Frequency_log, Monetary_log) %>%
  scale() %>%
  as.data.frame()

summary(rfm_scaled)

# 8. DÉTERMINATION DU NOMBRE OPTIMAL DE CLUSTERS

set.seed(123)

## Méthode du coude (Within Sum of Squares)
fviz_nbclust(rfm_scaled, kmeans, method = "wss") +
  ggtitle("Méthode du coude")

## Score de silhouette moyen
fviz_nbclust(rfm_scaled, kmeans, method = "silhouette") +
  ggtitle("Score de silhouette")

## k = 4 retenu : bon compromis entre robustesse statistique
## et richesse d'interprétation métier

# 9. CLUSTERING K-MEANS

set.seed(123)
k <- 4

km_result <- kmeans(rfm_scaled, centers = k, nstart = 25)

## Ajout du cluster à chaque client
rfm_final <- rfm_log %>%
  mutate(Cluster = as.factor(km_result$cluster))

## Taille de chaque cluster
table(rfm_final$Cluster)

```

```
## Profil moyen de chaque cluster (sur les valeurs réelles, non transformées)
rfm_final %>%
  group_by(Cluster) %>%
  summarise(
    n = n(),
    Recency_moy = mean(Recency),
    Frequency_moy = mean(Frequency),
    Monetary_moy = mean(Monetary)
  )
```

10. VISUALISATION DES CLUSTERS

```
## Projection 2D des clusters (via ACP)
fviz_cluster(km_result, data = rfm_scaled,
  geom = "point", ellipse.type = "convex",
  palette = "jco", ggtheme = theme_minimal()) +
  ggtitle("Segmentation des clients (K-means, k=4)")

## Boxplots des variables RFM par cluster
rfm_final %>%
  select(Cluster, Recency, Frequency, Monetary) %>%
  pivot_longer(cols = c(Recency, Frequency, Monetary),
    names_to = "Variable", values_to = "Valeur") %>%
  ggplot(aes(x = Cluster, y = Valeur, fill = Cluster)) +
  geom_boxplot() +
  facet_wrap(~Variable, scales = "free") +
  theme_minimal() +
  ggtitle("Distribution des variables RFM par cluster")

## Effectif de clients par cluster (diagramme en barres)
ggplot(rfm_final, aes(x = Cluster, y = after_stat(count), fill = Cluster)) +
  geom_bar() +
  labs(title = "Nombre de clients par cluster",
    x = "Cluster", y = "Effectif") +
  theme_minimal()
```

11. VALIDATION PAR CLUSTERING HIÉRARCHIQUE

```
## Sur un échantillon car le calcul serait trop lourd sur les 4338 clients,
## on vérifie que la structure en 4 groupes est cohérente avec le K-means.
```

```
set.seed(123)

sample_idx <- sample(1:nrow(rfm_scaled), 500)
rfm_sample <- rfm_scaled[sample_idx, ]

dist_matrix <- dist(rfm_sample, method = "euclidean")
hc <- hclust(dist_matrix, method = "ward.D2")
```

```

## Dendrogramme
plot(hc, labels = FALSE, main = "Dendrogramme (échantillon 500 clients)",
     xlab = "", sub = "")
rect.hclust(hc, k = 4, border = "red")

# 12. ATTRIBUTION DES LABELS MÉTIER

segment_map <- rfm_final %>%
  group_by(Cluster) %>%
  summarise(Monetary_moy = mean(Monetary)) %>%
  arrange(desc(Monetary_moy)) %>%
  mutate(Segment = c("Champions", "Fidèles réguliers",
                    "Récents / occasionnels", "Inactifs / perdus")[row_number()])

rfm_final <- rfm_final %>% left_join(segment_map %>% select(Cluster, Segment), by =
"Cluster")

## Vérification finale
table(rfm_final$Segment)

# 13. EXPORT DES RÉSULTATS

## Export CSV pour archivage / réutilisation
write.csv(rfm_final, "rfm_segmentation_finale.csv", row.names = FALSE)

## Sauvegarde des objets R (pour reprise ultérieure sans tout relancer)
saveRDS(list(rfm_final = rfm_final, km_result = km_result, hc = hc),
        "resultats_segmentation.RDS")

```